

STL-10 实验报告

1. 网络结构设计

我在本项目主要实现了两类模型：

- `simple_cnn`：自定义的轻量 CNN，包含 4 个 convolution block，每个 block 由 Conv2d、BatchNorm(可选)、activation 和 pooling 组成，最后使用 global average pooling 与 fully connected classifier 输出 10 类预测。
- `resnet18`：基于 Kaiming He 的 ResNet-18 的结构，针对 96x96 图像将首层改为 `3x3 stride=1` convolution，并移除原始 ImageNet ResNet 中过早下采样的 max pooling，使模型更适合 STL-10 小尺寸图像。

2. 实验设置

评价指标包括 Accuracy、Precision、Recall、F1-score 和 confusion matrix。训练过程中记录训练集与验证集的 Loss 和 Accuracy，并绘制曲线观察收敛过程与过拟合情况。所有实验均训练 30 个 epoch，batch size 为 64。

本实验围绕课程要求的三个优化角度设计对比：

实验名	模型	数据增强	正则化/归一化	optimizer	lr
baseline_simple_cnn	simple_cnn	none	无 BatchNorm / Dropout	SGD	0.03
aug_simple_cnn	simple_cnn	RandomCrop、HorizontalFlip	无 BatchNorm / Dropout	SGD	0.03
regularized_simple_cnn	simple_cnn	RandomCrop、HorizontalFlip	BatchNorm、Dropout=0.3	AdamW	0.001
resnet18_adamw	resnet18	RandomCrop、HorizontalFlip	BatchNorm、Dropout=0.3	AdamW	0.001

其中，`aug_simple_cnn` 用于验证数据增强效果，`regularized_simple_cnn` 用于验证 BatchNorm、Dropout 和 optimizer 调整的效果，`resnet18_adamw` 用于比较更加现代的模型结构带来的变化。


3. 实验结果


实验名	Best Epoch	Best Valid Acc	Test Acc	Test Macro F1	Test Weighted F1
baseline_simple_cnn	29	60.29%	61.60%	0.6031	0.6031
aug_simple_cnn	28	66.29%	67.10%	0.6751	0.6751
regularized_simple_cnn	30	76.29%	75.90%	0.7544	0.7544
resnet18_adamw	26	74.57%	75.00%	0.7504	0.7504

从结果看，数据增强使测试 Accuracy 从 61.60% 提升到 67.10%；继续引入 BatchNorm、Dropout，并将 optimizer 从 SGD 换为 AdamW 后，测试 Accuracy 提升到 75.90%。这说明数据增强和正则化对于模型的泛化能力都有提升。

ResNet-18 的测试 Accuracy 为 75.00%，略低于正则化后的轻量 CNN，这说明在本实验的数据规模和训练轮数下，更复杂的结构并不一定直接带来更好的最终泛化效果。

四个实验的训练曲线如下：






最佳模型为 `regularized_simple_cnn`，其最终测试集分类报告如下：

类别	Precision	Recall	F1-score
airplane	0.9255	0.8700	0.8969
bird	0.7143	0.8500	0.7763
car	0.7638	0.9700	0.8546
cat	0.7013	0.5400	0.6102
deer	0.6316	0.8400	0.7210
dog	0.6479	0.4600	0.5380
horse	0.7248	0.7900	0.7560
monkey	0.7386	0.6500	0.6915
ship	1.0000	0.7700	0.8701
truck	0.8095	0.8500	0.8293

该模型在 `car`、`airplane`、`ship`、`truck` 等轮廓较稳定、背景相对清晰的类别上表现较好；其中 `car` 的 Recall 达到 0.9700，`ship` 的 Precision 达到 1.0000。较难类别主要是 `dog`、`cat`、`monkey`，这几类动物在姿态、背景和局部纹理上更容易混淆。根据 `regularized_simple_cnn` 的 confusion matrix，`dog` 容易被误分为 `deer`、`horse`、`cat`、`monkey`，`cat` 也常被误分到 `deer`、`dog`、`monkey`，说明动物类别之间的细粒度差异仍是主要错误来源。

最佳模型的 confusion matrix 如下：



4. 过拟合分析

基础模型 `baseline_simple_cnn` 在最后一个 epoch 的训练 Accuracy 达到 91.55%，但验证 Accuracy 只有 60.29%，同时训练 Loss 为 0.2656、验证 Loss 为 1.8612，二者差距很大，说明模型已经明显过拟合。该模型没有使用数据增强、BatchNorm 和 Dropout，因此训练集拟合较快，但泛化能力不足。

加入 RandomCrop 和 HorizontalFlip 后，`aug_simple_cnn` 的最终训练 Accuracy 为 73.76%，验证 Accuracy 为 64.57%，训练与验证差距明显缩小。数据增强增加了输入扰动，使模型不能简单记忆训练图像，因此测试 Accuracy 从 61.60% 提升到 67.10%。


`regularized_simple_cnn` 在第 30 个 epoch 取得最佳验证 Accuracy 76.29%，测试 Accuracy 75.90%，是本次实验中表现最好的模型。它的最终训练 Accuracy 为 87.73%，验证 Accuracy 为 76.29%，仍然存在一定过拟合，但相比 baseline 已明显缓解。BatchNorm 改善了训练稳定性，Dropout 降低了 classifier 对局部特征组合的依赖，AdamW 也使收敛过程更加稳定。

`resnet18_adamw` 的最佳验证 Accuracy 出现在第 26 个 epoch，为 74.57%，测试 Accuracy 为 75.00%。虽然 ResNet-18 具有更强表达能力，但在 30 epoch 设置下并未超过正则化后的轻量 CNN。可能原因是 ResNet-18 参数量更大，对训练轮数、学习率和正则化强度更敏感，同时 STL-10 本次训练集规模相对有限。

5. Grad-CAM

我们使用 Grad-CAM 对 `resnet18_adamw` 的预测过程进行可视化。每个类别各取一张测试图像进行可视化。

示例：



从可视化结果看，模型在正确识别 `car` 样本时，热力图主要集中在车身和车轮附近，说明模型确实利用了目标主体区域进行判断。对于一张真实类别为 `airplane` 但被预测为 `ship` 的样本，Grad-CAM 热力图同时覆盖了飞机、水面和背景区域，模型可能受港口、水面等上下文影响，将图像误判为 `ship`。这说明模型不仅依赖目标物体本身，也会受到背景线索影响。

6. AI 工具使用说明

本项目的代码框架部分由 OpenAI Codex(GPT 5.5) 辅助生成,主要在数据处理和训练pipeline管线搭建阶段使用了AI工具。